

picoclaw によるリモート Windows ロック・ログイン機能仕様書

最終更新: 2026-02-25

概要

NanoKVM-USB デスクトップアプリに組み込まれた AI エージェント「picoclaw」を通じて、自然言語の指示でリモート接続された Windows PC のロック・ログイン操作を行う機能です。

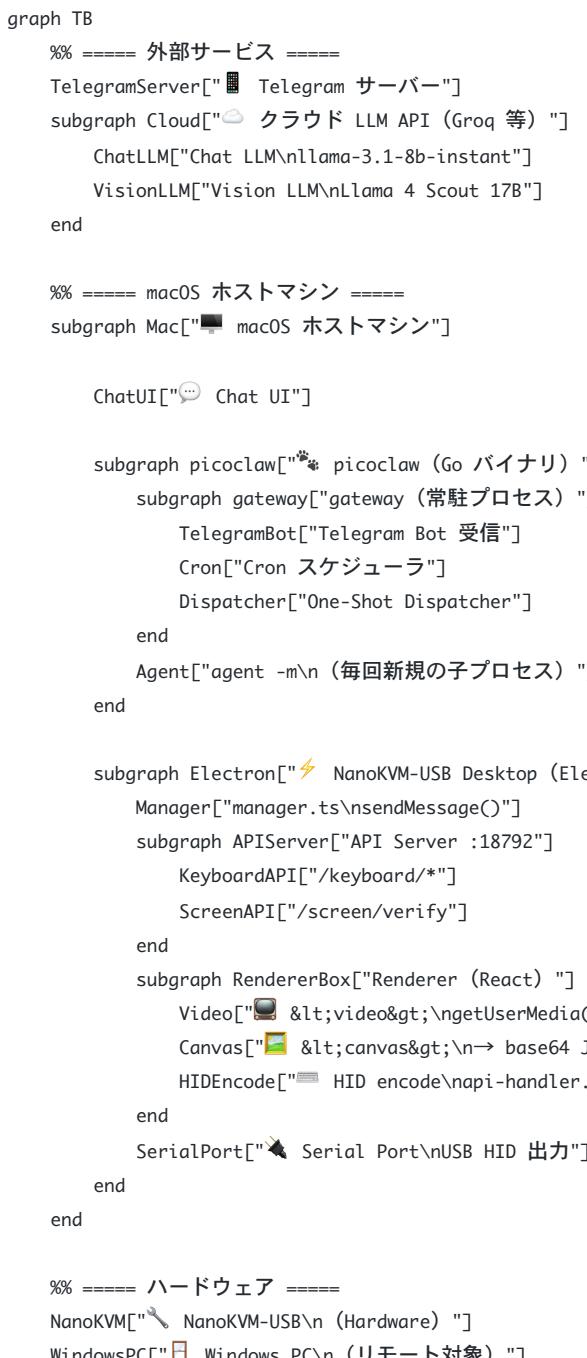
入力経路: チャット UI (アプリ内) または Telegram ボット

出力先: NanoKVM-USB ハードウェア経由で Windows PC に HID キーボード入力を送信

処理方式: 両経路とも `picoclaw agent -m` を毎回サブプロセスとして起動 (One-Shot 方式)

システム構成ブロック図

全体アーキテクチャ



```

%% ===== 接続線 =====
%% Telegram 経路
TelegramServer -- "Bot API" --> TelegramBot
TelegramBot --> Dispatcher
Cron --> Dispatcher
Dispatcher -- "spawn\n (メッセージごと)" --> Agent

%% Chat UI 経路
ChatUI --> Manager
Manager -- "spawn\nagent -m" --> Agent

%% agent → LLM
Agent -- "HTTPS\nChat LLM 呼出" --> ChatLLM

%% agent → API Server (Tool 実行)
Agent -- "HTTP POST\nTool 実行" --> KeyboardAPI
Agent -- "HTTP POST\n画面検証" --> ScreenAPI

%% API Server → Renderer (操作系)
KeyboardAPI -- "IPC" --> HIDEncode
HIDEncode -- "IPC" --> SerialPort

%% API Server → Renderer (映像キャプチャ系)
ScreenAPI -- "IPC\nキャプチャ要求" --> Canvas
Video -- "drawImage()" --> Canvas
Canvas -- "IPC\nbase64 JPEG" --> ScreenAPI
ScreenAPI -- "HTTPS\nbase64 JPEG 送信" --> VisionLLM

%% ハードウェア接続
SerialPort -- "USB" --> NanoKVM
NanoKVM -- "USB HID\n操作転送" --> WindowsPC
WindowsPC -- "HDMI\n映像出力" --> NanoKVM
NanoKVM -- "USB UVC\n映像転送" --> Video

%% スタイル
style Cloud fill:#e8f4fd,stroke:#4a90d9
style picoclaw fill:#f0f9e8,stroke:#7cb342
style Electron fill:#fff3e0,stroke:#ff9800
style gateway fill:#e8f5e9,stroke:#66bb6a
style RendererBox fill:#fce4ec,stroke:#e91e63
style APIServer fill:#fff8e1,stroke:#ffc107
style NanoKVM fill:#f3e5f5,stroke:#9c27b0
style WindowsPC fill:#e3f2fd,stroke:#2196f3

```

Telegram ロック操作のシーケンス図

```

sequenceDiagram
    actor User as ユーザー
    participant TG as Telegram
    participant GW as gateway<br>(常駐)
    participant Agent as agent -m<br>(子プロセス)
    participant ChatLLM as Chat LLM<br>(Groq)
    participant API as API Server<br>:18792
    participant Render as Renderer
    participant KVM as NanoKVM
    participant WinPC as Windows PC

```

User->>TG: 「ロックして」

TG->>GW: Bot API 通知

Note over GW: One-Shot Dispatcher

GW->>Agent: spawn (新規プロセス)

```
rect rgb(232, 244, 253)
```

Note over Agent,ChatLLM: Chat LLM にユーザー意図を問い合わせ

Agent->>ChatLLM: HTTPS (メッセージ送信)

ChatLLM-->Agent: Tool Call: nanokvm_lock

end

```
rect rgb(255, 243, 224)
```

Note over Agent,WinPC: Win+L キー送信

Agent->>API: POST /keyboard/type

API->>Render: IPC (HID encode)

Render->>KVM: Serial Port (USB)

KVM->>WinPC: USB HID (Win+L)

Note over WinPC: ロック画面に遷移

end

Note over Agent: ⏳ 3秒待機

```
rect rgb(252, 228, 236)
```

Note over Agent,ChatLLM: 画面検証 (Vision LLM)

Agent->>API: POST /screen/verify

API->>Render: IPC (キャプチャ要求)

Note over Render: drawImage() → base64 JPEG

WinPC-->KVM: HDMI 映像

KVM-->Render: USB UVC 映像

Render-->>API: IPC (base64 JPEG)

API->>ChatLLM: HTTPS (Vision LLM)

Note right of ChatLLM: Llama 4 Scout
画面を解析

ChatLLM-->>API: "LOCK_SCREEN"

API-->>Agent: 検証結果

end

Agent-->>GW: stdout: "✅ ロック完了"

Note over Agent: プロセス終了

GW->>TG: 返信送信

TG->>User: "✅ ロック完了"

データフローの要点:

方向	フロー	説明
➡ 操作	Chat/Telegram → picoclaw agent -m → Chat LLM → Tool Call → API Server → Renderer → Serial Port → NanoKVM → Windows PC	キー・マウス操作の送信
⬅ 映像	Windows PC → HDMI → NanoKVM → USB (UVC) → Renderer <video> (getUserMedia)	HDMI 映像のリアルタイム表示
➡ 検証	API Server → Renderer canvas キャプチャ → base64 JPEG → Vision LLM (Groq) → 判定結果	画面キャプチャ + Vision 解析

対応コマンド

1. ロック（画面ロック）

項目	内容
操作内容	Windows のショートカット Win + L を送信
対応フレーズ例	「Windowsをロックして」「PCをロックしてください」「ロック」「lock the screen」
内部動作	Win キー押下 → L キー押下 → 100ms 保持 → 逆順にリリース
事後検証	3秒後に画面キャプチャ → Vision LLM で LOCK_SCREEN を確認

2. ログイン（PIN / パスワード入力）

項目	内容
操作内容	ロック画面を解除し、PIN コードまたはパスワードを入力してログイン
対応フレーズ例	「PINコード mypin でログインして」「パスワードで入って」「login with PIN」
事後検証	15秒後に画面キャプチャ → Vision LLM で結果を判定

ログインシーケンス（PINのみ）

ステップ	操作	目的	待機時間
0	Escape キー押下	前回のPINエラーダイアログが残っている場合に閉じる	300ms
1	Space キー押下	ロック画面からサインイン画面を呼び起す	500ms
1b	Space キー再押下	バックアップの起動操作	-
2	待機	Windows がPIN入力欄を描画・フォーカスするのを待つ	3,000ms
3	Backspace × 20回	入力欄の既存文字をクリア (Ctrl+A はPIN欄で無効のため)	各30ms間隔
4	PIN を1文字ずつ入力	HID キーボードレポートで各文字を送信	各150ms間隔
5	Enter キー押下	PIN を送信してログイン	-

ログインシーケンス（ユーザー名 + パスワード）

ステップ	操作	目的	待機時間
0	Escape キー押下	エラーダイアログを閉じる（前回失敗時の残り）	300ms
1～3	上記と同じ	画面起動・フィールドクリア	同上
4	ユーザー名を入力	ユーザー名欄にテキスト入力	300ms
5	Tab キー押下	パスワード欄に移動	300ms
6	パスワードを入力	パスワード欄にテキスト入力	300ms
7	Enter キー押下	ログイン実行	-

Note: ユーザーが明示的に指定しない限り、ユーザー名は送信されません。LLM がOS 名やボット名をユーザー名として使用することを防ぐバリデーションが入っています。

picoclaw ツール呼び出しの流れ

picoclaw は Go 側でネイティブなツール実行（function calling）を行います。また、LLM がテキスト中にツール呼び出しを埋め込むケースに備え、Electron 側のインターフェンス（manager.ts）がフォールバック検出を行います。

Go 側ネイティブツール（主要パス）

picoclaw agent はツール定義を LLM に渡し、構造化された function call で実行します:

ツール名	説明	パラメータ
nanokvm_lock	Win+L でロック	なし
nanokvm_login	PIN/パスワード入力でログイン	password, username?
nanokvm_shortcut	キーボードショートカット送信	keys[]
nanokvm_type	テキスト入力	text
nanokvm_mouse_click	マウスクリック	button

Electron 側インターフェンス（フォールバック）

LLM がテキスト出力にツール呼び出しを含めた場合の検出パターン（3形式対応）：

優先度	フォーマット	例
1	アクションタグ	<<nanokvm:login:mypin>>
2	JSON オブジェクト	{"type": "function", "name": "nanokvm_login", "parameters": {"password": "..."}}
3	Python 関数呼び出し	nanokvm_login(password='...')

重複実行防止

- 同一エンドポイント + 同一パラメータのリクエストは **15秒間の重複排除** (debounce)
- Go 側がネイティブ実行 → HTTP API 呼び出し → インターフェンスも同じ API を呼ぼうとする → debounce で弾かれる

レスポンスマッセージ

ユーザーに表示するメッセージは、LLM 出力からツール呼び出し構文を除去（stripActionTags）して生成されます。

除去対象

- <<nanokvm:...>> アクションタグ
- nanokvm_ を含む JSON オブジェクト
- nanokvm_xxx(...) 関数呼び出し構文
- LLM プリアンブル文（例: "The function call that best answers the prompt is:"）

フォールバック

除去後にテキストが空になった場合、「コマンドを実行しました」がデフォルトメッセージとして表示されます。

対応キーワード

ショートカットで使用できるキーワードは LLM の出力する一般的な名前から自動変換されます。

入力名	変換先 (HID コード)
Win, Windows, Meta, Cmd	MetaLeft
Ctrl, Control	ControlLeft
Alt, Option	AltLeft
Shift	ShiftLeft

Del	Delete
Esc	Escape
Return	Enter
A～Z（单一文字）	KeyA～KeyZ
0～9（单一数字）	Digit0～Digit9
F1～F24	F1～F24

API エンドポイント一覧

HTTP API サーバー（127.0.0.1:18792）が提供するエンドポイント：

メソッド	パス	パラメータ	説明
POST	/api/keyboard/shortcut	{"keys": ["Win", "L"]}	キーボードショートカット送信
POST	/api/keyboard/login	{"password": "...", "username?": "user"}	Windows ログイン実行
POST	/api/keyboard/type	{"text": "Hello"}	テキスト入力
POST	/api/mouse/click	{"button": "left"}	マウスクリック
GET	/api/screen/capture	なし	現在の画面をキャプチャ（base64 JPEG）
POST	/api/screen/verify	{"action": "lock" "login"}	画面状態を Vision LLM で検証

入力経路別の挙動

項目	チャット UI	Telegram
picoclaw 常駐プロセス	なし（都度起動）	picoclaw gateway（常駐）
メッセージ処理	manager.ts → spawn agent -m	One-Shot Dispatcher → spawn agent -m
LLM呼び出し	サブプロセス内	サブプロセス内（同一）
ツール実行	Go 側ネイティブ	Go 側ネイティブ（同一）
レスポンス表示	チャット吹き出し	Telegram メッセージ
セッション蓄積	なし（毎回フレッシュ）	なし（毎回フレッシュ）

制約事項

- 同時押しキー数：HID 仕様により最大6キー（修飾キーは別枠）
- 文字入力：ASCII 英数字・基本記号のみ対応（日本語入力は非対応）
- マウス移動：座標指定は未実装（クリックのみ対応）
- ログイン待機：PIN 入力後 15 秒の固定待機（デスクトップ描画完了まで）
- NanoKVM 操作回数：1メッセージあたり最大 4 回（不要な反復を防止）
- ユーザー名バリデーション："windows", "linux", "ubuntu" 等の OS 名は自動除外

チャット用 LLM（Chat LLM）

picoclaw のチャット機能（自然言語によるコマンド解釈・応答生成）に使用する LLM プロバイダとモデルの一覧です。自動更新機能によりモデルリストは定期的に更新されますが、以下が現在のデフォルト構成です。

チャット LLM プロバイダ・モデル一覧

プロバイダ	デフォルトモデル	認証方式	料金	備考
Groq	llama-3.3-70b-versatile	API Key	無料枠あり	推奨: 高速・クレカ不要
OpenAI	gpt-5.2	API Key	有料	高品質・安定
Anthropic	claude-sonnet-4.6	API Key	有料	高品質
DeepSeek	deepseek-chat	API Key	安価	コスト効率
Google Gemini	gemini-2.0-flash-exp	API Key	無料枠あり	高速
GitHub Copilot	gpt-4o-mini	OAuth (gh CLI)	無料	gh auth login で認証
OpenRouter	auto	API Key	従量制	多プロバイダ統合
Mistral AI	mistral-small-latest	API Key	有料	欧州拠点
Ollama	llama3	不要	無料	ローカル実行
VLLM	custom-model	不要	無料	ローカル実行
NVIDIA	nemotron-4-340b-instruct	API Key	要確認	GPU 推論
Cerebras	llama-3.3-70b	API Key	要確認	高速推論
Qwen	qwen-plus	API Key	安価	中国拠点
Zhipu AI	glm-4.7	API Key	安価	中国拠点
Moonshot	moonshot-v1-8k	API Key	安価	中国拠点
Volcengine	doubao-pro-32k	API Key	安価	ByteDance
ShengsuanYun	deepseek-v3	API Key	安価	中国拠点
Antigravity	gemini-3-flash	OAuth	要確認	Google Cloud

GitHub Copilot / GitHub Models 対応モデル

GitHub Copilot プロバイダは [GitHub Models API](#) を使用します。 gh auth login で取得した OAuth トークン (gho_*) で認証し、API キーの手動入力は不要です。

初回認証フロー

GitHub Copilot を使用するには GitHub CLI (gh) のインストールと認証が必要です。 アプリ内の 「🔑 GitHub 認証を開始」 ボタンから以下のフローで認証できます:

```
sequenceDiagram
    actor User as ユーザー
    participant UI as ⚡ NanoKVM-USB<br>設定画面
    participant Main as Main Process
    participant GH as 🐳 gh CLI
    participant Browser as 🌐 ブラウザ<br>github.com/login/device

    Note over UI: 🛒 GitHub Copilot 接続設定<br>⚠ GitHub 認証が必要です
```

User->>UI: 「🔑 GitHub 認証を開始」 クリック

UI->>Main: IPC: INITIATE_GITHUB_AUTH

rect rgb(255, 243, 224)

```

Note over Main,GH: gh CLI で Device Flow 開始
Main->>GH: spawn: gh auth login<br>-h github.com -p https -w
GH-->Main: stderr: one-time code<br>「XXXX-XXXX」
end

Main-->UI: { code: "XXXX-XXXX", url }

rect rgb(232, 244, 253)
Note over UI,Browser: デバイスコード表示 + ブラウザ起動
UI-->UI: 画面にコード表示<br>「XXXX-XXXX」
UI-->Browser: shell.openExternal()<br>github.com/login/device
User-->Browser: コードを入力
User-->Browser: 認証を許可
end

rect rgb(232, 245, 233)
Note over UI,GH: ポーリングで認証完了を検出
loop 3秒間隔ポーリング (最大5分)
UI-->Main: IPC: DETECT_GITHUB_AUTH
Main-->GH: gh auth token
GH-->Main: gho_xxxxxx (OAuth トークン)
Main-->UI: { found: true, token, user }
end
end

UI-->UI: ✅ GitHub 認証済み (user: xxx)
UI-->UI: トークンを config に自動保存
UI-->User: 🎉 認証完了通知

```

前提条件:

- [GitHub CLI \(gh \)](#) がインストール済み
- GitHub アカウントを持っている（無料アカウントでOK）
- GitHub Copilot の登録は不要（GitHub Models API は全ユーザーに無料提供）

実装ファイル:

ファイル	役割
manager.ts → initiateGitHubAuth()	gh auth login --web を spawn、デバイスコード取得
manager.ts → detectGitHubToken()	gh auth token でトークン検出
manager.ts → cancelGitHubAuth()	認証プロセスを kill
picoclaw.ts (events)	IPC ハンドラ (INITIATE_GITHUB_AUTH, CANCEL_GITHUB_AUTH)
picoclaw.tsx (renderer)	UI: デバイスコード表示、ポーリング、完了通知

モデル名	種別	Vision	備考
gpt-4o-mini	Chat	✓	デフォルト: 高速・軽量
gpt-4o	Chat	✓	高品質
gpt-4.1	Chat	✓	最新世代
gpt-4.1-mini	Chat	✓	最新世代・軽量
gpt-4.1-nano	Chat	-	超軽量

o1	Reasoning	-	推論特化
o3	Reasoning	-	推論特化
o3-mini	Reasoning	-	推論特化・軽量
o4-mini	Reasoning	-	最新推論モデル
Meta-Llama-3.1-405B-Instruct	Chat	-	大型オープン
Meta-Llama-3.1-8B-Instruct	Chat	-	軽量オープン
Llama-3.2-11B-Vision-Instruct	Chat	<input checked="" type="checkbox"/>	Vision対応: 画面検証に使用可能
Llama-3.2-90B-Vision-Instruct	Chat	<input checked="" type="checkbox"/>	Vision対応: 高精度
Phi-4	Chat	-	Microsoft 軽量
Phi-4-multimodal-instruct	Chat	<input checked="" type="checkbox"/>	Vision対応: Microsoft
DeepSeek-R1	Reasoning	-	推論特化
MAI-DS-R1	Reasoning	-	Microsoft + DeepSeek
Mistral-large-2407	Chat	-	Mistral 大型

Note: GitHub Copilot の Web/VS Code 版では Claude 等の Anthropic モデルも選択可能ですが、 GitHub Models API (`models.inference.ai.azure.com`) ではサポートされていません。 picoclaw は GitHub Models API を経由するため、上記のモデルのみ利用可能です。

モデルリスト自動更新機能

picoclaw のモデルリストは、プロバイダが新モデルを追加した際に自動更新されます。

概要

- 更新対象:** 各プロバイダが提供するモデルの一覧 (`~/.picoclaw/config.json` の `model_list`)
- 更新元:** `picoclaw providers` コマンドで取得するデフォルトモデル + UI 上の追加定義
- 表示:** 設定画面のモデル選択ドロップダウンに反映

スケジュール設定

項目	オプション	デフォルト
頻度	日次 / 週次 / 月次	月次
実行時刻	0:00 ~ 23:00	0:00
曜日 (週次)	月～日	月曜日
日付 (月次)	1～28日	1日
有効/無効	トグル	有効

更新フロー

```

flowchart TD
    Start["⚡️ Electron 起動時<br>ModelUpdater.init()"] --> CheckSchedule
    CheckSchedule["📅 スケジュール確認<br>config.json 読み込み"] --> CalcNext["⌚ 次回実行時刻を計算<br>setTimeout() 設定"]

```

```

CalcNext -- "時刻到達" --> RunProviders["PICOLAW providers<br>コマンド実行"]
Manual["👤 手動: ⏪ 今すぐ更新"] --> RunProviders

RunProviders --> UpdateConfig["📝 config.json の<br>model_list を更新"]

UpdateConfig --> CheckModel{"現在のモデルが<br>新リストに存在する?"}

CheckModel -- "✅ 存在する" --> NoChange["変更なし"]
CheckModel -- "❌ 存在しない" --> AutoSwitch["⚠️ デフォルトモデルに<br>自動切替 + 警告表示"]

NoChange --> CalcNext
AutoSwitch --> CalcNext

style Start fill:#fff3e0,stroke:#ff9800
style RunProviders fill:#f0f9e8,stroke:#7cb342
style CheckModel fill:#e8f4fd,stroke:#4a90d9
style AutoSwitch fill:#fce4ec,stroke:#e91e63
style Manual fill:#e8f5e9,stroke:#66bb6a

```

手動更新

設定画面の「⌚ 今すぐ更新」ボタンで即時実行できます。

Config 構造（自動更新関連）

```
{
  "model_update": {
    "enabled": true,
    "frequency": "monthly",
    "hour": 0,
    "dayOfMonth": 1
  }
}
```

ステータスは `~/.picoclaw/model-update-status.json` に保存:

```
{
  "lastChecked": "2026-02-25T00:00:00Z",
  "nextCheck": "2026-03-01T00:00:00Z",
  "lastUpdatedModels": ["groq: 4 models", "openai: 1 model"],
  "autoSwitched": false
}
```

画面検証機能（Vision LLM）

ロック・ログインコマンド実行後、NanoKVM-USB の HDMI キャプチャ映像をスクリーンキャプチャし、専用の Vision LLM で画面内容を解析して結果を自動判定します。

設計思想: チャット用 LLM と Vision LLM の分離

```

block-beta
  columns 1
  block:settings["⚙️ 設定画面 (picoclaw.tsx)"]
    columns 2
    block:chat["💬 チャット LLM":2]

```

```

columns 2
chatProvider["Provider: Groq"]
chatModel["Model: llama-3.1-8b-instant"]
chatKey["API Key: gsk_..."]:2
end
block:vision["⌚ 画面検証 Vision LLM"]:2
columns 2
visionProvider["Provider: Groq"]
visionModel["Model: Llama 4 Scout 17B 🕵️"]
visionKey["API Key: gsk_... (共有可)"]:2
end
end

style settings fill:#fff3e0,stroke:#ff9800
style chat fill:#e8f4fd,stroke:#4a90d9
style vision fill:#fce4ec,stroke:#e91e63

```

理由: チャットには安価なテキスト LLM、画面検証には Vision 対応 LLM という使い分け。例: チャット = llama-3.1-8b-instant (Groq 無料) + Vision = Llama 4 Scout (Groq 無料)

検証フロー



```
style DesktopWarn fill:#fff8e1,stroke:#ff9800  
style WaitNote fill:none,stroke:none
```

Vision プロンプト

Vision LLM には画面内容に応じた専用プロンプトを使用:

- ロック検証: "Is this a Windows lock screen or a desktop?" → LOCK_SCREEN / DESKTOP
- ログイン検証: "What is the Windows login status?" → LOGIN_SUCCESS / LOGIN_FAILED / LOCK_SCREEN
 - タスクバーの有無を重視 (タスクバーが見える = デスクトップ = LOGIN_SUCCESS)

NanoKVM 操作の早期終了条件

Vision 検証の結果が以下のいずれかを含むとき、picoclaw は追加の LLM 呼び出しを行わず即座にユーザーに結果を返します:

結果	条件	動作
✓ 成功	応答に ✓ を含む	早期終了・成功として返却
✗ 失敗	応答に ✗ / LOGIN_FAILED を含む	早期終了・失敗として返却
⚠ 未完了	応答に ⚠ / LOCK_SCREEN を含む	早期終了・警告として返却

これにより、不要な反復 LLM 呼び出し (→ 429 エラー) を防止します。

Vision LLM 未設定時の振る舞い

Vision LLM が設定されていない場合:

- 事後検証: Go 側で callScreenVerify() が呼ばれるが、API Server が「未設定」を返却
- ツール結果は「✓ 操作完了」で返される (検証なし)
- 初回操作時に設定案内メッセージが表示される

Vision LLM 対応モデル一覧

プロバイダ	モデル	料金	速度	備考
Groq	meta-llama/llama-4-scout-17b-16e-instruct	無料	高速 (~500ms)	推奨: Llama 4 Scout · クレカ不要
Groq	meta-llama/llama-4-maverick-17b-128e-instruct	無料	高速	Llama 4 Maverick · 高精度
Groq	llama-3.2-11b-vision-preview	無料	高速	Llama 3.2 11B Vision
Groq	llama-3.2-90b-vision-preview	無料	低速	Llama 3.2 90B Vision · 高精度
GitHub Copilot	gpt-4o-mini	無料	高速	gh 認証のみ · 推奨
GitHub Copilot	gpt-4o	無料	高速	高品質
GitHub Copilot	gpt-4.1	無料	高速	最新世代
GitHub Copilot	gpt-4.1-mini	無料	高速	最新世代 · 軽量
GitHub Copilot	Llama-3.2-11B-Vision-Instruct	無料	中速	オープンモデル

GitHub Copilot	Llama-3.2-90B-Vision-Instruct	無料	低速	高精度
GitHub Copilot	Phi-4-multimodal-instruct	無料	中速	Microsoft モデル
Ollama	moondream2:latest	無料	~60秒	1.7B・ローカル・CPU向き
Ollama	moondream:latest	無料	~60秒	Moondream v1
Ollama	llava:latest	無料	~3分	LLaVA 7B・高精度
Ollama	llava:7b	無料	~3分	LLaVA 7B 明示指定
Ollama	llava:13b	無料	~5分	LLaVA 13B・高精度・要GPU
Ollama	llava-llama3:latest	無料	~3分	LLaVA-Llama3・新世代
Ollama	bakllava:latest	無料	~3分	BakLLaVA・Mistral ベース
OpenRouter	google/gemini-2.0-flash-001	安価	高速	Gemini 2.0 Flash
OpenRouter	google/gemini-pro-1.5	安価	中速	Gemini Pro 1.5
OpenRouter	anthropic/clause-3.5-sonnet	高額	中速	Claude 3.5 Sonnet
OpenRouter	anthropic/clause-3-5-sonnet	高額	中速	Claude 3.5 Sonnet (旧ID)
OpenRouter	anthropic/clause-3-haiku	安価	高速	Claude 3 Haiku
OpenRouter	openai/gpt-4o	高額	中速	GPT-4o (OpenRouter 経由)
OpenRouter	openai/gpt-4o-mini	安価	高速	GPT-4o Mini (OpenRouter 経由)
OpenAI	gpt-4o-mini	安価	高速	推奨・低成本
OpenAI	gpt-4o	高額	中速	高精度
OpenAI	gpt-4-turbo	高額	低速	GPT-4 Turbo
Anthropic	claude-3-5-haiku-20241022	安価	高速	コスト効率
Anthropic	claude-3-5-sonnet-20241022	高額	中速	高精度
Anthropic	claude-3-opus-20240229	最高額	低速	最高精度
Anthropic	claude-3-sonnet-20240229	高額	中速	バランス
Anthropic	claude-3-haiku-20240307	安価	高速	旧世代・高速

タイムアウト設定

プロバイダ	検証遅延 (ロック)	検証遅延 (ログイン)	API タイムアウト
クラウド (Groq等)	3秒	15秒	30秒
Ollama (ローカル)	5秒	15秒	120秒

Config 構造

```
{
  "agents": {
```

```

"defaults": {
  "provider": "groq",
  "model": "llama-3.1-8b-instant",
  "vision_provider": "groq",
  "vision_model": "meta-llama/llama-4-scout-17b-16e-instruct"
},
"providers": {
  "groq": { "api_key": "gsk_..." }
},
"model_list": {
  "groq": ["llama-3.1-8b-instant", "meta-llama/llama-4-scout-17b-16e-instruct"]
}
}

```

レートリミット対策

Groq 無料枠 (TPM 6000) での運用を前提とした対策:

対策	説明
One-Shot 方式	セッション蓄積なし → トークン消費を最小化
早期終了	✓ / ✗ / ⚠ で即座に返却 → 追加 LLM 呼び出し不要
NanoKVM 回数制限	1メッセージあたり最大 4 回
REDACTED 拒否	LLM がパスワードを *** にマスクした場合は実行拒否
429 ポップアップ	レートリミット時にリトライ待ち時間を UI に表示